

Bài thi cuối module 4

Thời gian làm bài: 3.5 tiếng

Nhóm ra đề thi AIO

1 Lý thuyết

1.1 Random Forest

i Quy ước và tham số chung: Random Forest

- Trong toàn bộ các câu hỏi, mỗi lần phân tách tại một nút đều là *binary split* (chỉ tách hai nhánh).
- Mọi phép tính đều làm tròn đến **2 chữ số** thập phân (ví dụ: 0.005 làm tròn thành 0.01).
- Lời giải viết tắt lớp: CN = “Cháy nắng”, K = “Không”.

Tập dữ liệu $\mathcal{D}$:

ID	Màu tóc	Chiều cao	Cân nặng	Dùng kem	Kết quả
1	Đen	Trung bình	Nhẹ	Không	Cháy nắng
2	Đen	Cao	Trung bình	Có	Không
3	Râm	Thấp	Trung bình	Có	Không
4	Nâu	Thấp	Trung bình	Không	Cháy nắng
5	Nâu	Trung bình	Nặng	Không	Cháy nắng
6	Râm	Trung bình	Nặng	Có	Không

Công thức tính Gini Impurity và Gini Gain

Gini Impurity của một tập S :

$$G(S) = 1 - \sum_c p_c^2$$

Gini Gain khi phân tách tập S theo thuộc tính A :

$$GG(S, A) = G(S) - \sum_{v \in \text{nhánh}} \frac{|S_v|}{|S|} G(S_v)$$

AIO25M04RF01

Một mẫu bootstrap $\mathcal{D}_1$ được tạo với tập ID là $\{1, 2, 3, 3, 4, 5\}$. Gini Impurity của mẫu bootstrap này là bao nhiêu?

- A. 0.50
- B. 0.38
- C. 0.44
- D. 0.25

Đáp án đúng: A. 0.50

Giải thích:

- Dữ liệu trong mẫu bootstrap $\mathcal{D}_1$ bao gồm các mẫu có ID: $\{1, 2, 3, 3, 4, 5\}$.
- Dựa vào bảng dữ liệu gốc, ta có các kết quả tương ứng: $\{\text{Cháy nắng}, \text{Không}, \text{Không}, \text{Không}, \text{Cháy nắng}, \text{Cháy nắng}\}$.
- Đếm số lượng mỗi lớp: có **3 mẫu "Cháy nắng"** và **3 mẫu "Không"**.
- Tỷ lệ mỗi lớp là $p_{CN} = 3/6 = 0.5$ và $p_K = 3/6 = 0.5$.
- Áp dụng công thức Gini Impurity:

$$G(\mathcal{D}_1) = 1 - (p_{CN}^2 + p_K^2) = 1 - (0.5^2 + 0.5^2) = 1 - (0.25 + 0.25) = 0.5.$$

AIO25M04RF02

Vấn xét trên mẫu bootstrap $\mathcal{D}_1 = \{1, 2, 3, 3, 4, 5\}$. Tại nút gốc, nếu thuật toán chỉ được chọn ngẫu nhiên trong 2 đặc trưng là **“Màu tóc”**, **“Cân nặng”**, giá trị Gini Gain lớn nhất có thể đạt được là bao nhiêu?

- A. 0.13
- B. 0.50
- C. 0.08
- D. 0.25

Đáp án đúng: D. 0.25

Giải thích: Gini gốc của $\mathcal{D}_1$ (3 CN, 3 K) là $G_{\text{gốc}} = 0.5$. Ta xét tất cả các cách chia nhị phân có thể có cho mỗi đặc trưng:

- **Xét đặc trưng “Màu tóc”:** Các giá trị có trong mẫu là $\{\text{Đen}, \text{Đen}, \text{Râm}, \text{Râm}, \text{Nâu}, \text{Nâu}\}$.
 - Chia theo $\{\text{Đen}\}$ vs $\{\text{Râm}, \text{Nâu}\}$: Nhánh trái (ID 1,2) có (1 CN, 1 K), Gini=0.5. Nhánh phải (ID 3,3,4,5) có (2 CN, 2 K), Gini=0.5.

$$\text{Gain} = 0.5 - \left(\frac{2}{6} \times 0.5 + \frac{4}{6} \times 0.5\right) = 0.$$

- Chia theo {Râm} vs {Đen, Nâu}: Nhánh trái (ID 3,3) có (0 CN, 2 K), Gini=0. Nhánh phải (ID 1,2,4,5) có (3 CN, 1 K), Gini=0.375.

$$\text{Gain} = 0.5 - \left(\frac{2}{6} \times 0 + \frac{4}{6} \times 0.375\right) = 0.25.$$

- Chia theo {Nâu} vs {Đen, Râm}: Nhánh trái (ID 4,5) có (2 CN, 0 K), Gini=0. Nhánh phải (ID 1,2,3,3) có (1 CN, 3 K), Gini=0.375.

$$\text{Gain} = 0.5 - \left(\frac{2}{6} \times 0 + \frac{4}{6} \times 0.375\right) = 0.25.$$

- **Xét đặc trưng “Cân nặng”**: Các giá trị có trong mẫu là {Nhẹ, Trung bình, Trung bình, Trung bình, Nặng, Trung bình}.

- Chia theo {Nhẹ} vs {Trung bình, Nặng}: Nhánh trái (ID 1) có (1 CN, 0 K), Gini=0. Nhánh phải (ID 2,3,3,4,5) có (2 CN, 3 K), Gini=0.48.

$$\text{Gain} = 0.5 - \left(\frac{1}{6} \times 0 + \frac{5}{6} \times 0.48\right) = 0.10.$$

- Chia theo {Nặng} vs {Nhẹ, Trung bình}: Nhánh trái (ID 5) có (1 CN, 0 K), Gini=0. Nhánh phải (ID 1,2,3,3,4) có (2 CN, 3 K), Gini=0.48.

$$\text{Gain} = 0.5 - \left(\frac{1}{6} \times 0 + \frac{5}{6} \times 0.48\right) = 0.10.$$

- Chia theo {Trung bình} vs {Nhẹ, Nặng}: Nhánh trái (ID 2,3,3,4) có (1 CN, 3 K), Gini=0.375. Nhánh phải (ID 1,5) có (2 CN, 0 K), Gini=0.

$$\text{Gain} = 0.5 - \left(\frac{4}{6} \times 0.375 + \frac{2}{6} \times 0\right) = 0.25.$$

So sánh tất cả các trường hợp, Gini Gain lớn nhất có thể đạt được là **0.250**.

AIO25M04RF03

Vấn xét trên mẫu bootstrap $\mathcal{D}_1 = \{1, 2, 3, 3, 4, 5\}$, giả sử ở nút gốc ta đã chọn cách chia “Cân nặng = Trung bình?”. Sau đó, xét một **nút con không thuần khiết** chứa các mẫu có ID **{2, 3, 3, 4}**. Tại nút này, nếu thuật toán chỉ được chọn ngẫu nhiên trong 2 đặc trưng **{“Màu tóc”, “Dùng kem”}**, Gini Gain lớn nhất có thể đạt được là bao nhiêu?


- A. 0.13.
- B. 0.25.
- C. 0.38.
- D. 0.44.

Đáp án đúng: C. 0.38

Giải thích: Nút con cần tách chứa các mẫu {ID 2, 3, 3, 4}, có (1 CN, 3 K). Gini gốc của nút này là $G_{con} = 1 - ((1/4)^2 + (3/4)^2) = 0.375$.

- **Xét đặc trưng “Dùng kem”**: Các giá trị là {Có, Có, Có, Không}. Cách chia duy nhất là {Có} vs {Không}.
 - Nhánh Đúng (ID {2, 3, 3}): có (0 CN, 3 K) $\rightarrow$ Gini = 0 (thuần khiết).
 - Nhánh Sai (ID {4}): có (1 CN, 0 K) $\rightarrow$ Gini = 0 (thuần khiết).
 - $\text{Gain} = 0.375 - (\frac{3}{4} \times 0 + \frac{1}{4} \times 0) = 0.375$.
- **Xét đặc trưng “Màu tóc”**: Các giá trị là {Đen, Râm, Râm, Nâu}. Cách chia tốt nhất là {Nâu} vs {Đen, Râm}.
 - Nhánh Đúng (ID {4}): có (1 CN, 0 K) $\rightarrow$ Gini = 0 (thuần khiết).
 - Nhánh Sai (ID {2, 3, 3}): có (0 CN, 3 K) $\rightarrow$ Gini = 0 (thuần khiết).
 - $\text{Gain} = 0.375 - (\frac{1}{4} \times 0 + \frac{3}{4} \times 0) = 0.375$.

Cả hai đặc trưng đều có thể đạt được Gini Gain tối đa là **0.38**.



AIO25M04RF04

Xét quá trình xây một cây quyết định trên **toàn bộ tập dữ liệu gốc $\mathcal{D}$** . Cây phân tách lần đầu tại nút gốc bằng câu hỏi “Màu tóc = Đen?”. Sau đó, nó tiếp tục phân tách nút con tương ứng với nhánh sai (tức Màu tóc $\neq$ Đen) bằng câu hỏi “Dùng kem = Có?”. Gini Impurity của nút lá chứa mẫu ID 4 là bao nhiêu?


- A. 0.50
- B. 0.00
- C. 0.38
- D. 0.44

Đáp án đúng: B. 0.00

Giải thích: Mẫu ID 4 có “Màu tóc” là “Nâu” ($\neq$ Đen) và “Dùng kem” là “Không” ($\neq$ Có).

- **Nút gốc:** Mẫu ID 4 đi theo nhánh **sai** của câu hỏi “Màu tóc = Đen?”.
- **Nút con:** Nút này chứa các mẫu {3, 4, 5, 6}. Nó được tách bằng câu hỏi “Dùng kem = Có?”.
- **Nút lá:** Mẫu ID 4 đi theo nhánh **sai**. Nút lá này chứa các mẫu có (Màu tóc $\neq$ Đen) và (Dùng kem = Không), tức là {ID 4, 5}.
- **Tính Gini:** Nút lá {4, 5} chứa 2 mẫu “Cháy nắng” và 0 mẫu “Không”.

$$G(\text{lá}) = 1 - ((2/2)^2 + (0/2)^2) = 1 - 1 = 0.$$



AIO25M04RF05

Sai số Out-of-Bag (OOB) là một cách đánh giá hiệu suất của Random Forest. Quy trình cho mỗi mẫu trong dữ liệu gốc như sau:

1. Tìm tất cả các cây trong rừng **không** được huấn luyện trên mẫu này (đây là các cây OOB của mẫu).
2. Để các cây OOB này dự đoán nhãn cho mẫu này.
3. Kết hợp các dự đoán này bằng bỏ phiếu đa số để có dự đoán OOB cuối cùng.

Tỷ lệ lỗi OOB = (Số mẫu dự đoán sai) / (Tổng số mẫu được đánh giá)

Xét hai trường hợp sau:

- **Với mẫu ID 2 (nhãn gốc: “Không”):** Có 3 cây OOB của Random Forest đưa ra dự đoán là: [“Không”, “Không”, “Cháy nắng”].

- Với mẫu ID 5 (nhãn gốc: “Cháy nắng”): Có 4 cây OOB của Random Forest đưa ra dự đoán là: [“Không”, “Cháy nắng”, “Không”, “Không”].

Dựa trên kết quả trên hai mẫu này, tỷ lệ lỗi OOB (tỷ lệ các mẫu được đánh giá bị dự đoán sai) là bao nhiêu?

- A. 0%
- B. 25%
- C. 50%
- D. 100%

Đáp án đúng: C. 50%


Giải thích:

- Mẫu ID 2 (nhãn gốc: “Không”):
 - Các phiếu bầu: 2 cho “Không”, 1 cho “Cháy nắng”.
 - Dự đoán OOB (đa số): “Không”.
 - So với nhãn gốc: “Không” == “Không” → **Đúng**.
- Mẫu ID 5 (nhãn gốc: “Cháy nắng”):
 - Các phiếu bầu: 3 cho “Không”, 1 cho “Cháy nắng”.
 - Dự đoán OOB (đa số): “Không”.
 - So với nhãn gốc: “Không” ≠ “Cháy nắng” → **Sai**.
- **Tính tỷ lệ lỗi:** Đã đánh giá 2 mẫu, trong đó có 1 mẫu bị dự đoán sai.


$$\text{Tỷ lệ lỗi OOB} = \frac{\text{Số mẫu dự đoán sai}}{\text{Tổng số mẫu được đánh giá}} = \frac{1}{2} = 50\%.$$

AIO25M04RF06

Một Random Forest với 3 cây cần dự đoán cho mẫu mới $X = (\text{Màu tóc}=\text{Đen}, \text{Chiều cao}=\text{Cao}, \text{Cân nặng}=\text{Trung bình}, \text{Dùng kem}=\text{Có})$. Hai cây đầu tiên trong rừng có cấu trúc như trong hình:



Hình 1: Cây 1.



Hình 2: Cây 2.

Cây 3 được xây dựa trên các thông tin sau:

- Mẫu bootstrap $\mathcal{D}_3 = \{1, 2, 4, 5, 5, 6\}$.
- Tại nút gốc, 2 đặc trưng được chọn ngẫu nhiên là {"Màu tóc", "Cân nặng"}.
- Tại nút con không thuần khiết (nếu có), 2 đặc trưng được xét là {"Chiều cao", "Dùng kem"}.


Dự đoán cuối cùng của cả khu rừng cho mẫu X là gì?

- A. Cháy nắng
- B. Không
- C. Không thể xác định
- D. Nặng

Đáp án đúng: B. Không

Giải thích:

1. **Dự đoán của Cây 1:** Mẫu X có 'Dùng kem = Có', đi theo nhánh "Đúng" → dự đoán **Không**.
2. **Dự đoán của Cây 2:** Mẫu X có 'Cân nặng = Trung bình' (không phải Nhẹ), đi theo nhánh "Sai". Tại nút tiếp theo "Màu tóc = Đen?", mẫu X có 'Màu tóc = Đen', đi theo nhánh "Đúng" → dự đoán **Cháy nắng**.
3. **Xây dựng và dự đoán Cây 3:** Dựa trên $\mathcal{D}_3$, cây tối ưu được xây như sau:



Duyệt Cây 3 với mẫu X:

- Mẫu X có 'Màu tóc = Đen' ($\neq$ Nâu) → đi nhánh "Sai".

- Tại nút con, mẫu X có ‘Dùng kem = Có’ $\rightarrow$ đi nhánh “Đúng”.
 - Dự đoán của Cây 3 là **Không**.
4. **Tổng hợp phiếu bầu:** {Cây 1: **Không**, Cây 2: **Cháy nắng**, Cây 3: **Không**}.
5. **Kết luận:** Có 2 phiếu “Không” và 1 phiếu “Cháy nắng”. Dự đoán cuối cùng là **Không**.

1.2 AdaBoost

1.2.1 Bài toán AdaBoost Regression

i Quy ước và tham số chung: AdaBoost Regression

Quy ước làm tròn: mọi phép tính đều làm tròn đến **2 chữ số** thập phân (ví dụ: 0.005 làm tròn thành 0.01).

Tham số chung:

- Số lượng vòng lặp: 2.
- Độ sâu tối đa của cây con (f_t): 1.
- Quy tắc phân nhánh: $\leq$ threshold sẽ nằm bên trái, và ngược lại.
- Ngưỡng đã chọn: $t = 58.5$.
- Giá trị lá: `left_value = 3.23`, `right_value = 2.03`.
- Trọng số ban đầu: $w^1 = \left(\frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}\right)$
- Bộ học yếu (stump) ở vòng m : $h_m(x) \in \mathbb{R}$.
- Hàm mất mát chuẩn hoá theo từng mẫu (Linear):

$$e_i = \frac{|y_i - h_m(x_i)|}{\max_j |y_j - h_m(x_j)|} \in [0, 1].$$

Lưu ý: Tổng các trọng số w có thể không đúng bằng 1 do làm tròn 2 chữ số ở mọi bước.

Tập dữ liệu cho bài toán AdaBoost Regression:

ID	age	oldpeak
P6	53	3.10
P7	70	2.60
P8	62	1.90
P9	55	3.40
P10	54	3.20
P11	71	1.60

AIO25M04AB01: Trong vòng lặp đầu tiên của AdaBoost Regression, ta tính được sai số trung bình có trọng số ε_1 dựa trên công thức trọng số mẫu và hàm mất mát (Linear). Giá trị ε_1 gần bằng bao nhiêu?

Biết công thức tính sai số trung bình có trọng số: $\varepsilon_m = \sum_{i=1}^n w_i^{(m)} e_i$.

A. 0.44.

B. 0.54.

C. 0.63.

D. 0.73.

Đáp án đúng: A. 0.44.**Giải thích:**

$$\varepsilon_1 = \sum_{i=1}^6 w_i^{(1)} e_i = \underbrace{0.17 \times 0.23}_{0.04} + \underbrace{0.17 \times 1.00}_{0.17} + \underbrace{0.17 \times 0.23}_{0.04} + \underbrace{0.17 \times 0.30}_{0.05} + \underbrace{0.17 \times 0.05}_{0.01} + \underbrace{0.17 \times 0.75}_{0.13} = 0.44.$$

$$\varepsilon_1 \approx 0.44.$$

AIO25M04AB02: Sau khi tính được ε_1 , trọng số α_1 của cây con (f_1) được xác định theo công thức AdaBoost Regression. Giá trị α_1 gần bằng bao nhiêu?
Sử dụng các công thức sau:

$$\text{Tỉ số lỗi: } \beta_m = \frac{\varepsilon_m}{1 - \varepsilon_m}, \quad \text{Trọng số bộ học yếu: } \alpha_m = \ln\left(\frac{1}{\beta_m}\right).$$

A. 0.24.

B. 0.34.

C. 0.48.

D. 0.58.

Đáp án đúng: A. 0.24.**Giải thích:**

$$\beta_1 = \frac{\varepsilon_1}{1 - \varepsilon_1} = \frac{0.44}{1.00 - 0.44} = \frac{0.44}{0.56} = 0.79, \quad \alpha_1 = \ln\left(\frac{1}{\beta_1}\right) = \ln\left(\frac{1.00}{0.79}\right) = \ln(1.27) = 0.24.$$

$$\beta_1 \approx 0.79, \quad \alpha_1 \approx 0.24.$$

AIO25M04AB03: Sau khi cập nhật, vector trọng số mẫu đã được chuẩn hóa w_1 thu được gần bằng bao nhiêu?
Biết các công thức sau:

$$\text{Trọng số mẫu: } w_i^{(m+1)} = \frac{w_i^{(m)} \beta_m^{1-e_i}}{Z_m}, \quad \text{Hằng số chuẩn hoá: } Z_m = \sum_{i=1}^N w_i^{(m)} \beta_m^{1-e_i}.$$

- A. [0.16, 0.19, 0.16, 0.16, 0.16, 0.18].
 B. [0.26, 0.29, 0.26, 0.16, 0.25, 0.28].
 C. [0.11, 0.12, 0.13, 0.14, 0.15, 0.35].
 D. [0.20, 0.20, 0.20, 0.20, 0.10, 0.10].

Đáp án đúng: A. [0.16, 0.19, 0.16, 0.16, 0.16, 0.18].

Giải thích:

$$w_i^{(2)} = \frac{w_i^{(1)} \beta_1^{1-e_i}}{Z_1}, \quad Z_1 = \sum_{i=1}^6 w_i^{(1)} \beta_1^{1-e_i}.$$

ID	e_i	$1 - e_i$	$\beta_1^{1-e_i}$	$w_i^{(1)} \beta_1^{1-e_i}$
P6	0.23	0.77	0.83	0.14
P7	1.00	0.00	1.00	0.17
P8	0.23	0.77	0.83	0.14
P9	0.30	0.70	0.85	0.14
P10	0.05	0.95	0.80	0.14
P11	0.75	0.25	0.94	0.16
Tổng Z_1				0.89

$$w^{(2)} = \left(\frac{0.14}{0.89}, \frac{0.17}{0.89}, \frac{0.14}{0.89}, \frac{0.14}{0.89}, \frac{0.14}{0.89}, \frac{0.16}{0.89} \right) \approx (0.16, 0.19, 0.16, 0.16, 0.16, 0.18).$$

1.2.2 Bài toán AdaBoost Binary Classification

i Quy ước và tham số chung: AdaBoost Binary Classification

Quy ước làm tròn: mọi phép tính đều làm tròn đến **2 chữ số** thập phân (ví dụ: 0.005 làm tròn thành 0.01).

Tham số chung:

- Số lượng vòng lặp: 2.
- Nhãn phân loại: $fbs \in \{0, 1\}$ được mã hoá sang $y \in \{-1, +1\}$.
- Độ sâu tối đa của cây con (f_t): 1.
- Quy tắc phân nhánh: $\leq threshold$ sẽ nằm bên trái, và ngược lại.
- Ngưỡng đã chọn: $t_1 = 41, t_2 = 49$.
- Bộ học yếu (stump) ở vòng m : $h_m(x) \in \{-1, +1\}$.
- Dự đoán lá: $left_pred = 0, right_pred = 1$, (0 tương ứng -1 , 1 tương ứng $+1$ cho $h_m(x)$).
- Trọng số ban đầu: $w^1 = \left(\frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}\right)$

Lưu ý: Tổng các trọng số w có thể không đúng bằng 1 do làm tròn 2 chữ số ở mọi bước.

Tập dữ liệu cho bài toán AdaBoost Binary Classification:

ID	age	fbs
P0	38	0
P1	43	1
P2	39	0
P3	62	1
P4	45	0
P5	53	1

AIO25M04AB04: Trong vòng lặp đầu tiên của AdaBoost Classification, hằng số chuẩn hoá Z_1 gần đúng bằng bao nhiêu?

Sử dụng các công thức sau:

$$\text{Tỉ lệ lỗi có trọng số: } \varepsilon_m = \sum_{i=1}^N w_i^{(m)} \mathbf{1}(h_m(x_i) \neq y_i), \quad \text{Trọng số của bộ học yếu: } \alpha_m = \frac{1}{2} \ln \frac{1 - \varepsilon_m}{\varepsilon_m},$$

$$\text{Hằng số chuẩn hoá: } Z_m = \sum_{i=1}^N w_i^{(m)} e^{-\alpha_m y_i h_m(x_i)}, \quad e^{-\alpha_m y_i h_m(x_i)} = \begin{cases} e^{-\alpha_m}, & \text{nếu } h_m(x_i) = y_i, \\ e^{+\alpha_m}, & \text{nếu } h_m(x_i) \neq y_i. \end{cases}$$

- A. 0.55.
B. 0.67.
C. 0.70.
D. 0.78.

Đáp án đúng: D. 0.78.

Giải thích:

$$\text{Quy tắc: } h_1(x) = \begin{cases} -1, & \text{nếu age} \leq 41 \\ +1, & \text{nếu age} > 41 \end{cases}.$$

ID	age	y	$h_1(x)$	$\mathbf{1}(h_m(x_i) \neq y_i)$
P0	38	-1	-1	Đúng
P1	43	+1	+1	Đúng
P2	39	-1	-1	Đúng
P3	62	+1	+1	Đúng
P4	45	-1	+1	Sai
P5	53	+1	+1	Đúng

Tỉ lệ lỗi có trọng số (1 mẫu sai, trọng số 0.17):

$$\varepsilon_1 = \sum_i w_i^{(1)} \mathbf{1}[h_1(x_i) \neq y_i] = 0.17.$$

Trọng số của bộ học yếu:

$$\begin{aligned} 1 - \varepsilon_1 &= 1.00 - 0.17 = 0.83, \\ \frac{1 - \varepsilon_1}{\varepsilon_1} &= \frac{0.83}{0.17} \approx 4.88, \\ \ln\left(\frac{1 - \varepsilon_1}{\varepsilon_1}\right) &\approx \ln(4.88) = 1.59, \\ \alpha_1 &= \frac{1}{2} \cdot 1.59 = 0.80. \end{aligned}$$

Hệ số mũ:

$$e^{+\alpha_1} \approx e^{0.80} = 2.23, \quad e^{-\alpha_1} \approx e^{-0.80} = 0.45.$$

Hằng số chuẩn hoá:

$$\begin{aligned} Z_1 &= \sum_i w_i^{(1)} e^{-\alpha_1 y_i h_1(x_i)} = \underbrace{5 \times (0.17 \times 0.45)}_{5 \text{ mẫu đúng}} + \underbrace{1 \times (0.17 \times 2.23)}_{1 \text{ mẫu sai}} \\ &= 5 \times 0.08 + 0.38 = 0.78. \end{aligned}$$

AIO25M04AB05: Sau vòng 1, vector trọng số mẫu w_1 là gì?

Biết trọng số mẫu: $w_i^{(m+1)} = \frac{w_i^{(m)} e^{-\alpha_m y_i h_m(x_i)}}{Z_m}$.

- A. $[0.12, 0.40, 0.12, 0.12, 0.12, 0.12]$.
- B. $[0.08, 0.60, 0.08, 0.08, 0.08, 0.08]$.
- C. $[0.15, 0.40, 0.15, 0.10, 0.10, 0.10]$.
- D. $[0.10, 0.10, 0.10, 0.10, 0.49, 0.10]$.

Đáp án đúng: D. $[0.10, 0.10, 0.10, 0.10, 0.49, 0.10]$.

Giải thích:

Cập nhật:

$$w_i^{(2)} = \frac{w_i^{(1)} e^{-\alpha_1 y_i h_1(x_i)}}{Z_1}.$$

Với mẫu đúng: $\frac{0.17 \cdot 0.45}{0.78} = \frac{0.08}{0.78} = 0.10$. Với mẫu sai (P4): $\frac{0.17 \cdot 2.23}{0.78} = \frac{0.38}{0.78} = 0.49$.

Theo thứ tự $[P0, P1, P2, P3, P4, P5]$:

$$w^{(2)} \approx (0.10, 0.10, 0.10, 0.10, 0.49, 0.10).$$

(tổng xấp xỉ 0.99 do làm tròn 2 chữ số ở mọi bước).

AIO25M04AB06: Dự đoán nhãn cuối cùng $\hat{y}$ sau 2 vòng boosting là gì?

Tổ hợp và dự đoán cuối:

$$F(x) = \sum_{m=1}^M \alpha_m h_m(x), \quad \hat{y} = \text{sign}(F(x)).$$

- A. $[-1, +1, -1, +1, +1, -1]$.
- B. $[-1, -1, -1, +1, +1, +1]$.
- C. $[-1, +1, +1, +1, -1, +1]$.
- D. $[-1, -1, -1, +1, -1, +1]$.

Đáp án đúng: D. $[-1, -1, -1, +1, -1, +1]$.

Giải thích:

Vòng 2 dùng ngưỡng $t_2 = 49$:

$$h_2(x) = \begin{cases} -1, & \text{nếu age} \leq 49 \\ +1, & \text{nếu age} > 49 \end{cases} \Rightarrow h_2 = [-1, -1, -1, +1, -1, +1].$$

Tỉ lệ lỗi có trọng số (chỉ P1 sai, trọng số 0.10):

$$\varepsilon_2 = 0.10, \quad \alpha_2 = \frac{1}{2} \ln \frac{1 - \varepsilon_2}{\varepsilon_2} = \frac{1}{2} \ln \frac{0.90}{0.10} = \frac{1}{2} \ln(9.00) = \frac{1}{2} \cdot 2.20 = 1.10.$$

Lấy $\alpha_1 = 0.80$ từ vòng 1.

Tổ hợp:

$$F(x) = \alpha_1 h_1(x) + \alpha_2 h_2(x), \quad \hat{y} = \text{sign}(F(x)).$$

ID	h_1	h_2	$\alpha_1 h_1$	$\alpha_2 h_2$	$F(x) = \alpha_1 h_1 + \alpha_2 h_2$
P0	-1	-1	-0.80	-1.10	-1.90
P1	+1	-1	+0.80	-1.10	-0.30
P2	-1	-1	-0.80	-1.10	-1.90
P3	+1	+1	+0.80	+1.10	+1.90
P4	+1	-1	+0.80	-1.10	-0.30
P5	+1	+1	+0.80	+1.10	+1.90

Suy ra:

$$\hat{y} = \text{sign}(F) = [-1, -1, -1, +1, -1, +1],$$

1.3 Gradient Boosting

i Quy ước và tham số chung: Gradient Boosting

Quy ước làm tròn: mọi phép tính đều làm tròn đến **2 chữ số** thập phân (ví dụ: 0.005 làm tròn thành 0.01).

Tham số chung:

- **Với bài toán hồi quy (MSE):** $r_i = y_i - F(x_i)$; cập nhật lá γ là *trung bình* residual trong lá; $\text{MSE} = \frac{1}{n} \sum_i (y_i - F(x_i))^2$.
- **Với bài toán nhị phân (logistic):** $p = \sigma(F) = \frac{1}{1+e^{-F}}$; $\text{loss} = \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$; Newton update $\gamma = \frac{\sum r}{\sum p(1-p)}$ với $r = y - p$.

Tập dữ liệu cho bài toán hồi quy

ID	x	y_{reg}
1	1	2
2	2	3
3	3	5
4	4	6

Tập dữ liệu cho bài toán nhị phân

ID	x	y_{bin}
1	1	0
2	2	0
3	3	1
4	4	1

AIO25M04GB01:

Với dữ liệu hồi quy đã cho, hãy: (i) suy ra F_0 tối ưu dạng hằng số (mô hình ban đầu) theo tiêu chuẩn tối thiểu MSE; (ii) tính vector residual $r_{i,1} = y_i - F_0(x_i)$ cho bốn điểm. Chọn phương án đúng.

- A. $F_0 = 3.50$ và $r = [-1.5, -0.5, +1.5, +2.5]$.
- B. $F_0 = 4.00$ và $r = [-2, -1, +1, +2]$.
- C. $F_0 = 4.00$ và $r = [-1, -1, +1, +1]$.
- D. $F_0 = 4.25$ và $r = [-2.25, -1.25, +0.75, +1.75]$.

Đáp án đúng: B. $F_0 = 4.00$ và $r = [-2, -1, +1, +2]$.

Giải thích:

$$F_0 = \arg \min_c \frac{1}{n} \sum_{i=1}^n (y_i - c)^2 \quad \Rightarrow \quad F_0 = \bar{y}_{\text{reg}} = \frac{1}{n} \sum_i y_i.$$

Với $y_{\text{reg}} = [2, 3, 5, 6]$ và $n = 4$:

$$\bar{y}_{\text{reg}} = \frac{2 + 3 + 5 + 6}{4} = 4.00.$$

Residual tại vòng 1:

$$r_{i,1} = y_i - F_0(x_i) \Rightarrow r = [2 - 4, 3 - 4, 5 - 4, 6 - 4] = [-2, -1, +1, +2].$$

Như vậy chọn đáp án **B** là đáp án đúng.

AIO25M04GB02: Tiếp nối câu AIO25M04GB01. Chọn ngưỡng tách $x < 2.5$. Giá trị lá: trái $\gamma_{1,1} = -1.50$, phải $\gamma_{2,1} = +1.50$. Suy ra $F_1(x) = 2.50$ cho $x \in \{1, 2\}$ và 5.50 cho $x \in \{3, 4\}$. Hỏi MSE_1 bằng bao nhiêu?

A. 0.50

B. 0.33

C. 0.25

D. 0.00

Đáp án đúng: C. 0.25

Giải thích:

Công thức sử dụng:

$$MSE_1 = \frac{1}{n} \sum_{i=1}^n (y_i - F_1(x_i))^2.$$

Từ kết quả của câu AIO25M04GB01 ta có $F_0(x) \equiv \bar{y} = 4.00$. Từ dữ kiện của đề bài, tách $x < 2.5$, giá trị lá $\gamma_{1,1} = -1.50$ (trái), $\gamma_{2,1} = +1.50$ (phải). Suy ra

$$F_1(x) = \begin{cases} 2.50, & x \in \{1, 2\}, \\ 5.50, & x \in \{3, 4\}. \end{cases} \rightarrow F_1(x) = [2.50, 2.50, 5.50, 5.50]$$

$$y_{\text{reg}} = (y_1, y_2, y_3, y_4) = (2, 3, 5, 6), \quad n = 4.$$

Tính sai số bình phương từng điểm:

$$(y_1 - F_1(x_1))^2 = (2 - 2.50)^2 = 0.25,$$

$$(y_2 - F_1(x_2))^2 = (3 - 2.50)^2 = 0.25,$$

$$(y_3 - F_1(x_3))^2 = (5 - 5.50)^2 = 0.25,$$

$$(y_4 - F_1(x_4))^2 = (6 - 5.50)^2 = 0.25.$$

Kết luận:

$$MSE_1 = \frac{0.25 + 0.25 + 0.25 + 0.25}{4} = \frac{1.00}{4} = 0.25, \quad \text{nên chọn đáp án C. 0.25.}$$

AIO25M04GB03: Nối tiếp câu AIO25M04GB02, sang vòng 2, xét residual $r_{i,2} = y_i - F_1(x_i)$ và tách $x < 1.5$ (lá trái $\{x_1\}$, lá phải $\{x_2, x_3, x_4\}$). Cho biết $\gamma_{1,2} = -0.50$ và $\gamma_{2,2} \approx 0.17$. Hãy cho biết giá trị $F_2(2)$ bằng bao nhiêu?

- A. 2.50
- B. 2.67
- C. 3.00
- D. 3.50

Đáp án đúng: B. 2.67

Giải thích:

Công thức sử dụng:

$$F_2(x_i) = F_1(x_i) + \gamma_{\text{leaf}(i)}, \quad \gamma_{\text{leaf}} = \frac{1}{|\mathcal{L}|} \sum_{j \in \mathcal{L}} (y_{\text{reg},j} - F_1(x_j)).$$

Dữ kiện vòng 1: $F_1 = [2.50, 2.50, 5.50, 5.50]$, $y_{\text{reg}} = [2, 3, 5, 6]$.

Residual đầu vòng 2:

$$r_2 = y_{\text{reg}} - F_1 = [-0.50, +0.50, -0.50, +0.50].$$

Áp giá trị lá cho split $x < 1.5$: $\gamma_{1,2} = -0.50$ cho $\{x_1\}$, $\gamma_{2,2} \approx 0.17$ cho $\{x_2, x_3, x_4\}$.

Cập nhật:

$$F_2 = F_1 + [\gamma_{1,2}, \gamma_{2,2}, \gamma_{2,2}, \gamma_{2,2}] = [2.00, 2.6667, 5.6667, 5.6667].$$

Đọc giá trị cần tìm:

$$F_2(2) = 2.6667 \xrightarrow{\text{làm tròn}} \boxed{2.67}.$$

AIO25M04GB04: Tiếp nối bối cảnh của câu AIO25M04GB03. Hỏi MSE_2 bằng bao nhiêu?

- A. 0.25
- B. 0.17
- C. 0.10
- D. 0.05

Đáp án đúng: B. 0.17

Giải thích:

Công thức sử dụng:

$$\text{MSE}_2 = \frac{1}{n} \sum_{i=1}^n (y_{\text{reg},i} - F_2(x_i))^2, \quad n = 4.$$

Từ kết quả câu AIO25M04GB03, ta có:

$$F_2(x) = [2.00, 2.6667, 5.6667, 5.6667].$$

$$y_{\text{reg}} = (y_1, y_2, y_3, y_4) = (2, 3, 5, 6), \quad n = 4.$$

Sai số từng điểm:

$$(y_1 - F_2(x_1))^2 = (2 - 2.00)^2 = 0.00,$$

$$(y_2 - F_2(x_2))^2 = (3 - 2.6667)^2 \approx 0.3333^2 \approx 0.1111,$$

$$(y_3 - F_2(x_3))^2 = (5 - 5.6667)^2 \approx (-0.6667)^2 \approx 0.4444,$$

$$(y_4 - F_2(x_4))^2 = (6 - 5.6667)^2 \approx 0.3333^2 \approx 0.1111.$$

$$\text{MSE}_2 = \frac{0.00 + 0.1111 + 0.4444 + 0.1111}{4} = \frac{0.6666}{4} \approx 0.1667 \xrightarrow{\text{làm tròn}} \boxed{0.17}.$$

AIO25M04GB05: Với tập dữ liệu cho bài toán phân loại nhị phân, khởi tạo $F_0 \equiv 0 \Rightarrow p_0 = \frac{1}{2}$. Tách $x < 2.5$ và cập nhật Newton ở vòng 1: $\gamma_{1,1} = -2.00$, $\gamma_{2,1} = +2.00$. Suy ra $F_1 = [-2, -2, 2, 2]$ và $p_1 = \sigma(F_1)$. Tính tổng *logistic loss*

$$L_1 = \sum_{i=1}^4 \left(-y_{\text{bin},i} \log p_{1,i} - (1 - y_{\text{bin},i}) \log(1 - p_{1,i}) \right).$$

A. 2.77

B. 1.39

C. 0.51

D. 0.25

Đáp án đúng: C. 0.51

Giải thích:

Công thức sử dụng: với $p_i = \sigma(F_i)$,

$$\ell_i = \begin{cases} -\log(1 - p_i), & y_{\text{bin},i} = 0, \\ -\log(p_i), & y_{\text{bin},i} = 1, \end{cases} \quad L_1 = \sum_{i=1}^4 \ell_i.$$

Xác suất tại $F = \pm 2$:

$$\sigma(2) = \frac{1}{1 + e^{-2}} \approx 0.8808, \quad \sigma(-2) = 1 - \sigma(2) \approx 0.1192.$$

Áp vào từng điểm: hai nhãn 0 có $F = -2 \Rightarrow p \approx 0.1192$ nên $\ell = -\log(1 - 0.1192) = -\log(0.8808) \approx 0.1278$. Hai nhãn 1 có $F = 2 \Rightarrow p \approx 0.8808$ nên $\ell = -\log(0.8808) \approx 0.1278$.

Tổng loss:

$$L_1 \approx 4 \times 0.1278 = 0.5112 \xrightarrow{\text{làm tròn}} \boxed{0.51}.$$

AIO25M04GB06: Với tập dữ liệu cho bài toán phân loại nhị phân, nối tiếp câu AIO25M04GB05. Áp dụng *Newton theo từng lá* liên tiếp trong hai vòng để cập nhật F_1 rồi F_2 . Hãy tính $p_2(x_1) = \sigma(F_2(x_1))$ với $\sigma(z) = \frac{1}{1+e^{-z}}$

A. 0.04

B. 0.08

C. 0.12

D. 0.16

Đáp án đúng: A. 0.04

Giải thích:

Với bài toán nhị phân (dùng $y_{\text{bin}} = [0, 0, 1, 1]$), khởi tạo $F_0 \equiv 0 \Rightarrow p_0 = \sigma(0) = 0.50$. Tách $x < 2.5$ tạo hai lá: trái $\{x_1, x_2\}$, phải $\{x_3, x_4\}$. Áp dụng Newton theo từng lá để thu được F_1 , rồi lặp Newton một lần nữa để suy ra F_2 , cuối cùng tính $p_2(x_1)$.

Công thức sử dụng:

$$p = \sigma(F) = \frac{1}{1 + e^{-F}}, \quad r = y - p, \quad \gamma = \frac{\sum r}{\sum p(1 - p)}, \quad F_{\text{new}} = F_{\text{old}} + \gamma \text{ (theo từng lá)}.$$

Bước 1: Vòng Newton thứ nhất (từ F_0 ra F_1).

Từ dữ kiện câu AIO25M04GB05, ta có:

$$F_1 = [-2, -2, 2, 2], \quad p_1 = \sigma(F_1) = [0.1192, 0.1192, 0.8808, 0.8808].$$

Bước 2: Vòng Newton thứ hai (từ F_1 ra F_2).

Tại mỗi điểm: $p_1(1 - p_1) = 0.1192 \times 0.8808 \approx 0.1050$.

– Lá trái ($y = 0, 0$):

$$r = y - p_1 = [-0.1192, -0.1192] \Rightarrow \sum r = -0.2384,$$

$$\sum p(1 - p) = 2 \times 0.1050 = 0.2100 \Rightarrow \gamma_{L,2} = \frac{-0.2384}{0.2100} \approx -1.14.$$

– Lá phải ($y = 1, 1$):

$$r = y - p_1 = [0.1192, 0.1192] \Rightarrow \sum r = +0.2384, \quad \sum p(1 - p) = 0.2100 \Rightarrow \gamma_{R,2} = \frac{0.2384}{0.2100} \approx +1.14.$$

Cập nhật

$$F_2 = F_1 + \begin{bmatrix} \gamma_{L,2} \\ \gamma_{L,2} \\ \gamma_{R,2} \\ \gamma_{R,2} \end{bmatrix} \approx [-2 - 1.14, -2 - 1.14, 2 + 1.14, 2 + 1.14] = [-3.14, -3.14, 3.14, 3.14].$$

Bước 3: Tính $p_2(x_1)$.

$$p_2(x_1) = \sigma(F_2(x_1)) = \sigma(-3.14) = \frac{1}{1 + e^{3.14}} \approx \frac{1}{1 + 23.10} \approx 0.0415 \xrightarrow{\text{làm tròn 2 cs}} \boxed{0.04}.$$

1.4 XGBoost

i Quy ước và tham số chung: XGBoost

Quy ước làm tròn: mọi phép tính đều làm tròn đến **2 chữ số** thập phân (ví dụ: 0.005 làm tròn thành 0.01).

Tham số chung:

- Bài toán hồi quy dùng hàm mất mát MSE (Mean Squared Error), trong khi bài toán phân loại dùng Logistic.
- Learning rate $\eta = 0.3$.
- Regularization (L2) $\lambda = 1.0$.
- Min split gain $\gamma = 0.0$.
- Độ sâu tối đa của cây con (f_t): 1.
- Quy tắc phân nhánh: $\leq threshold$ sẽ nằm bên trái, và ngược lại.

Tập dữ liệu cho bài toán hồi quy gồm 4 mẫu (x_i) với 2 đặc trưng (A_i) và nhãn tương ứng (y_i):

Index	A_1	A_2	y
1	1.00	2.00	3.00
2	1.50	0.50	2.00
3	2.00	1.50	4.00
4	2.50	2.00	5.00

AIO25M04XGB01: Trong **vòng lặp đầu tiên**, sau khi tính toán tất cả các ngưỡng ứng viên, ngưỡng được chọn để phân nhánh ...

- thuộc đặc trưng 1 với $gain = 1.33$.
- thuộc đặc trưng 1 với $gain = 0.75$.
- thuộc đặc trưng 2 với $gain = 1.75$.
- thuộc đặc trưng 2 với $gain = 0.75$.

Đáp án đúng: A.

Giải thích:

Vòng 1 lấy $F_0 = \bar{y} = (3 + 2 + 4 + 5)/4 = 3.50$. Khi đó:

$$g = [F_0 - y] = [0.50, 1.50, -0.50, -1.50], \quad h = [1, 1, 1, 1], \quad G_T = \sum g_i = 0, \quad H_T = 4.$$

Xét các ngưỡng ứng viên (giữa các giá trị liên tiếp):

$$A_1 : t \in \{1.25, 1.75, 2.25\}, \quad A_2 : t \in \{1.00, 1.75\}.$$


Tính Gain:

Split	Nhánh trái (Index)	Gain
$A_1 \leq 1.25$	$\{1\}$	0.10
$A_1 \leq 1.75$	$\{1, 2\}$	1.33
$A_1 \leq 2.25$	$\{1, 2, 3\}$	0.85
$A_2 \leq 1.00$	$\{2\}$	0.85
$A_2 \leq 1.75$	$\{2, 3\}$	0.33

Ngưỡng tốt nhất là $A_1 \leq 1.75$ với **Gain = 1.33**.

AIO25M04XGB02: Trong vòng lặp đầu tiên, sau khi tính trọng số của nút lá, ta tiến hành cập nhật mô hình, hãy chọn f_1 phù hợp nhất?

$$F_1 = F_0 + \eta \times f_1$$



- A. Hình A.
- B. Hình B.
- C. Hình C.
- D. Hình D.

Đáp án đúng: C.

Giải thích:


Với split $A_1 \leq 1.75$, ta có các index cho nhánh trái gồm $\{1, 2\}$ và nhánh phải là $\{3, 4\}$.

$$G_L = 0.50 + 1.50 = 2.00, \quad H_L = 2 \Rightarrow w_L^* = -\frac{2.00}{2+1} = -0.67.$$

$$G_R = -0.50 + (-1.50) = -2.00, \quad H_R = 2 \Rightarrow w_R^* = +\frac{2.00}{2+1} = +0.67.$$

Từ đây: $f_1(x) = -0.67$ (lá trái), $+0.67$ (lá phải), và với quy ước phân nhánh (ở đầu mục 1.4), $A_1 \leq 1.75$ sẽ thuộc nhánh trái và ngược lại, tuy nhiên, hãy xem xét cẩn thận giữa hình A và C, hình đúng là **Hình C**.

AIO25M04XGB03: Trong vòng lặp kế tiếp, giả sử biết được f_2 như hình bên dưới. Các giá trị của $F_2(x_i)$ là?



- A. $?_1 = ?_2 = 3.14, \quad ?_3 = ?_4 = 3.86.$
 B. $?_1 = ?_2 = 2.77, \quad ?_3 = ?_4 = 3.83.$
 C. $?_1 = ?_2 = 3.34, \quad ?_3 = ?_4 = 3.66.$
 D. $?_1 = ?_2 = 3.30, \quad ?_3 = ?_4 = 3.70.$

Đáp án đúng: A.

Giải thích:

Từ $F_1 = [3.30, 3.30, 3.70, 3.70]$, gradient vòng 2:

$$g = [F_1 - y] = [0.30, 1.30, -0.30, -1.30].$$

Split tối ưu vẫn là $A_1 \leq 1.75$ với trái gồm các index $\{1, 2\}$, nhánh phải gồm $\{3, 4\}$:

$$G_L = 1.60, \quad H_L = 2 \Rightarrow w_L^* = -\frac{1.60}{2+1} = -0.53,$$

$$G_R = -1.60, \quad H_R = 2 \Rightarrow w_R^* = +0.53.$$

Cập nhật:

$$\eta w_L^* = -0.16, \quad \eta w_R^* = +0.16.$$

Do đó F_2 tại $\{1, 2\}$: $3.30 - 0.16 = \mathbf{3.14}$; tại $\{3, 4\}$: $3.70 + 0.16 = \mathbf{3.86}$.

Tập dữ liệu cho bài toán phân loại gồm 4 mẫu (x_i) với 2 đặc trưng (A_i) và nhãn tương ứng (y_i).

Index	A_1	A_2	y
1	1.00	2.00	0
2	1.50	0.50	1
3	2.00	1.50	1
4	2.50	2.00	1

AIO25M04XGB04: Giá trị khởi tạo cho F_0 bằng?

- A. $F_0 = 0.75$.
- B. $F_0 = 1.00$.
- C. $F_0 = 1.10$.
- D. $F_0 = 0.50$.

Đáp án đúng: C.

Giải thích:

Với 3/4 mẫu dương, $p_0 = \frac{3}{4} = 0.75$.

Khởi tạo logit:

$$F_0 = \log \frac{p_0}{1 - p_0} = \log \frac{0.75}{0.25} = \log(3) = 1.10$$

AIO25M04XGB05: Giá trị gradient và hessian của nhánh trái (L) và nhánh phải (R) của ngưỡng 1.75 với đặc trưng A_2 bằng?

- A. $G_L = 0.50, \quad H_L = 0.38, \quad G_R = -0.50, \quad H_R = 0.38$.
- B. $G_L = -0.50, \quad H_L = 0.38, \quad G_R = 0.50, \quad H_R = 0.38$.
- C. $G_L = 0.75, \quad H_L = 0.19, \quad G_R = -0.75, \quad H_R = 0.57$.
- D. $G_L = -0.50, \quad H_L = 0.38, \quad G_R = 0.57, \quad H_R = -0.75$.

Đáp án đúng: B.

Giải thích:

Vòng 1, $F_0 = 1.10 \Rightarrow p_0 = \sigma(F_0) = 0.75$ cho mọi mẫu.

$$g_i = p_i - y_i = [0.75, -0.25, -0.25, -0.25],$$

$$h_i = p_i(1 - p_i) = 0.75 \times 0.25 = 0.19.$$

Với ngưỡng $A_2 \leq 1.75$: nhánh trái gồm các index $\{2, 3\}$, nhánh phải $\{1, 4\}$.

$$G_L = (-0.25) + (-0.25) = -\mathbf{0.50}, \quad H_L = 0.19 + 0.19 = \mathbf{0.38},$$

$$G_R = 0.75 + (-0.25) = +\mathbf{0.50}, \quad H_R = 0.19 + 0.19 = \mathbf{0.38}.$$

AIO25M04XGB06: Biết ngưỡng tốt nhất là 1.25 với đặc trưng A_1 , giá trị p của mẫu x_1 sau khi cập nhật mô hình là?

- A. 1.24.
- B. 0.91.
- C. 0.78.
- D. 0.71.

Đáp án đúng: D.

Giải thích:

Biết split tốt nhất là $A_1 \leq 1.25$ (nhánh trái chỉ có x_1). Ở vòng 1:

$$G_L = g_1 = 0.75, \quad H_L = 0.19, \quad G_R = -0.75, \quad H_R = 3 \times 0.19 = 0.57.$$

Trọng số lá:

$$w_L^* = -\frac{0.75}{0.19 + 1} = -0.63, \quad w_R^* = +\frac{0.75}{0.57 + 1} = +0.48.$$

Cập nhật cho x_1 :

$$F_1(x_1) = F_0 + \eta w_L^* = 1.10 + 0.3 \times (-0.63) = 0.91.$$

Suy ra $p_1(x_1) = \sigma(0.91) = \mathbf{0.71}$.

1.5 LightGBM

i Quy ước và tham số chung: LightGBM

Quy ước làm tròn: mọi phép tính đều làm tròn đến **2 chữ số** thập phân (ví dụ: 0.005 làm tròn thành 0.01).

Tham số chung:

- Bài toán hồi quy MSE (Mean Squared Error).
- Learning rate ($\eta = 1$).
- Regularization (L2) ($\lambda = 0$).
- Min split gain ($\gamma = 0$).

Do $\lambda = 0$ và $\gamma = 0$, sử dụng công thức gain rút gọn cho toàn bộ các câu AIO25M04LGBM01-06:

$$\mathcal{G} = \frac{G_L^2}{H_L} + \frac{G_R^2}{H_R}.$$

Tập dữ liệu:

Index	x	y
0	2	2
1	4	4
2	6	6
3	9	9
4	12	12
5	15	15

AIO25M04LGBM01: Cho bài toán hồi quy MSE với mô hình khởi tạo $F^{(0)} = \bar{y}$. Hãy tính vector gradient g và hessian h (ghi theo thứ tự chỉ số từ 0 đến 5).

- A. $g = [-6.00, -4.00, -2.00, 1.00, 4.00, 7.00]$, $h = [1, 1, 1, 1, 1, 1]$.
- B. $g = [-5.00, -3.00, -1.00, 2.00, 5.00, 8.00]$, $h = [1, 1, 1, 1, 1, 1]$.
- C. $g = [-6.00, -4.00, -2.00, 2.00, 4.00, 6.00]$, $h = [1, 1, 1, 1, 1, 1]$.
- D. $g = [-7.00, -5.00, -3.00, 0.00, 3.00, 6.00]$, $h = [1, 1, 1, 1, 1, 1]$.

Đáp án đúng: A. $g = [-6.00, -4.00, -2.00, 1.00, 4.00, 7.00]$, $h = [1, 1, 1, 1, 1, 1]$.

Giải thích:

Công thức sử dụng (MSE):

$$g_i = y_i - F^{(0)}(x_i), \quad h_i = 1, \quad F^{(0)} \equiv \bar{y} = 8.00.$$

Áp dụng vào dữ liệu:

$$g = y - 8 = [2 - 8, 4 - 8, 6 - 8, 9 - 8, 12 - 8, 15 - 8] = [-6, -4, -2, 1, 4, 7].$$

$$h \equiv 1 \Rightarrow h = [1, 1, 1, 1, 1, 1].$$

Như vậy g, h đúng với phương án A.

AIO25M04LGBM02: Dựng histogram với **equal-width** khi số bin $B = 3$. Dùng

$$w = \frac{\max - \min}{B}, \quad e_k = \min + k w \quad (k = 0..B),$$

và gán mẫu vào bin theo rìa trái đóng (bin cuối đóng cả hai phía). Hỏi *edges* và phân bin nào đúng?

- A. Edges [2.00, 6.33, 10.67, 15.00]; Bin0: {2, 4, 6}; Bin1: {9}; Bin2: {12, 15}.
- B. Edges [2.00, 4.33, 8.67, 15.00]; Bin0: {2, 4}; Bin1: {6, 9}; Bin2: {12, 15}.
- C. Edges [2.00, 6.33, 10.67, 15.00]; Bin0: {2, 4}; Bin1: {6, 9}; Bin2: {12, 15}.
- D. Edges [2.00, 5.00, 10.00, 15.00]; Bin0: {2, 4, 6}; Bin1: {9, 12}; Bin2: {15}.

Đáp án đúng: A. Edges [2.00, 6.33, 10.67, 15.00]; Bin0 {2, 4, 6}; Bin1 {9}; Bin2 {12, 15}.

Giải thích:

Công thức sử dụng (equal-width):

$$w = \frac{\max - \min}{B}, \quad e_k = \min + k w \quad (k = 0, \dots, B).$$

Áp dụng: $\min = 2, \max = 15 \Rightarrow w = \frac{15-2}{3} = \frac{13}{3} \approx 4.33$.

$$\text{Edges : } e_0 = 2.00, \quad e_1 = 2 + 4.33 = 6.33, \quad e_2 = 10.67, \quad e_3 = 15.00.$$

Gán bin (rìa trái đóng, bin cuối đóng cả hai phía):

$$\text{Bin}_0 = [2, 6.33] \Rightarrow \{2, 4, 6\}, \quad \text{Bin}_1 = (6.33, 10.67] \Rightarrow \{9\}, \quad \text{Bin}_2 = (10.67, 15] \Rightarrow \{12, 15\}.$$

Như vậy kết quả chính xác là phương án A.

AIO25M04LGBM03: Dựa trên histogram ở AIO25M04LGBM02, đánh giá hai rìa: *sau bin 0* và *sau bin 1* bằng công thức gain rút gọn. Midpoint threshold tương đương là trung điểm giữa $\max(\text{trái})$ và $\min(\text{phải})$, tìm best split (split tốt nhất). Chọn đáp án đúng.

- A. Sau bin 0, threshold 7.50.
- B. Sau bin 1, threshold 11.00.
- C. Hai rìa cho gain bằng nhau.

D. Không đủ thông tin để xác định.

Đáp án đúng: A. Sau bin 0, threshold 7.50.

Giải thích:

Công thức sử dụng (gain rút gọn):

$$\mathcal{G} = \frac{G_L^2}{H_L} + \frac{G_R^2}{H_R}, \quad G_{\{\cdot\}} = \sum g_i, \quad H_{\{\cdot\}} = \sum h_i, \quad (h_i \equiv 1).$$

Từ AIO25M04LGBM01: $g = [-6, -4, -2, 1, 4, 7]$. Từ AIO25M04LGBM02:

$$\text{Bin}_0 = \{2, 4, 6\}, \quad \text{Bin}_1 = \{9\}, \quad \text{Bin}_2 = \{12, 15\}.$$

Sau bin 0 (trái = Bin0, phải = Bin1 $\cup$ Bin2):

$$G_L = (-6) + (-4) + (-2) = -12, \quad H_L = 3; \quad G_R = 1 + 4 + 7 = 12, \quad H_R = 3.$$

$$\mathcal{G}_{(0)} = \frac{(-12)^2}{3} + \frac{12^2}{3} = 48 + 48 = 96.00.$$

Sau bin 1 (trái = Bin0 $\cup$ Bin1, phải = Bin2):

$$G_L = (-6) + (-4) + (-2) + 1 = -11, \quad H_L = 4; \quad G_R = 4 + 7 = 11, \quad H_R = 2.$$

$$\mathcal{G}_{(1)} = \frac{(-11)^2}{4} + \frac{11^2}{2} = 30.25 + 60.50 = 90.75.$$

So sánh $96.00 > 90.75 \Rightarrow$ rìa *sau bin 0* tốt hơn. Midpoint threshold giữa 6 và 9 là $(6+9)/2 = 7.50$.

AIO25M04LGBM04: Dùng split tốt nhất (sau bin 0 trong AIO25M04LGBM03). Với MSE, giá trị lá tính bởi

$$v = \frac{G}{H}, \quad \hat{y}^{(1)} = \hat{y}^{(0)} + \eta v.$$

Hãy chọn cặp (v_L, v_R) và hai giá trị dự đoán $\hat{y}$ tại lá trái/phải sau vòng 1.

A. $v_L = -4.00, v_R = +4.00$; lá trái/phải: 4.00 và 12.00.

B. $v_L = -3.00, v_R = +3.00$; lá trái/phải: 5.00 và 11.00.

C. $v_L = -6.00, v_R = +6.00$; lá trái/phải: 2.00 và 14.00.

D. $v_L = -2.00, v_R = +2.00$; lá trái/phải: 6.00 và 10.00.

Đáp án đúng: A. $v_L = -4.00, v_R = +4.00$; dự đoán lá trái/phải: 4.00 và 12.00.

Giải thích:

Công thức sử dụng:

$$v = \frac{G}{H}, \quad \hat{y}^{(1)} = \hat{y}^{(0)} + \eta v, \quad (\eta = 1, \hat{y}^{(0)} = \bar{y} = 8.00).$$

Tổng theo nhánh tại rìa *sau bin 0*:

$$(G_L, H_L) = (-12, 3) \Rightarrow v_L = \frac{-12}{3} = -4.00, \quad (G_R, H_R) = (+12, 3) \Rightarrow v_R = \frac{12}{3} = +4.00.$$

$$\hat{y}_{\text{left}}^{(1)} = 8 + (-4) = 4.00, \quad \hat{y}_{\text{right}}^{(1)} = 8 + 4 = 12.00.$$

Như vậy kết quả khớp phương án A.

AIO25M04LGBM05: Vẫn sử dụng *best split sau bin 0*. Áp dụng GOSS với $a = 0.2$, $b = 0.4$, $n = 6$:

- Giữ 1 mẫu có $|g|$ lớn nhất (nhóm a): **index [5]**, ứng với $(x = 15, y = 15, g = 7)$.
- Giả sử chọn ngẫu nhiên 2 mẫu từ phần còn lại (nhóm b): **index [2,3]**, ứng với $(x = 6, y = 6, g = -2)$ và $(x = 9, y = 9, g = 1)$, nhân với trọng số $s = \frac{1-a}{b}$.
- Chỉ sử dụng các index đã chọn ở hai nhóm trên để tính toán (các mẫu khác bị loại bỏ).

Tính *gain ước lượng* bằng thống kê có trọng số:

$$\mathcal{G}_{\text{GOSS}} = \frac{G_L^2}{H_L} + \frac{G_R^2}{H_R},$$

trong đó G, H là tổng theo *bin* sau khi nhân trọng số w_i .

Kết quả gần đúng nào đúng?

- A. 32.00 – 34.00.
- B. 34.50 – 35.50.
- C. 36.00 – 38.00.
- D. 40.00 – 42.00.

Đáp án đúng: B. 34.50–35.50.

Giải thích:

Công thức sử dụng (GOSS + gain rút gọn):

$$w_i = \begin{cases} 1, & \text{nằm trong nhóm } a, \\ s = \frac{1-a}{b}, & \text{nằm trong nhóm } b, \end{cases} \quad G_b = \sum_{i \in b} w_i g_i, \quad H_b = \sum_{i \in b} w_i h_i,$$

$$\mathcal{G}_{\text{GOSS}} = \frac{G_L^2}{H_L} + \frac{G_R^2}{H_R} \quad (\text{cộng theo phía trái/phải của rìa}).$$

Thiết lập: $g = [-6, -4, -2, 1, 4, 7]$.

$$a \cdot n = 1 \Rightarrow \text{nhóm } a : \text{index } 5 \ (g_5 = 7, w_5 = 1).$$

$$b \cdot n = 2 \Rightarrow \text{nhóm } b : \text{index } 2, 3 \ (g_2 = -2, \ g_3 = 1, \ s = \frac{1-0.2}{0.4} = 2.00).$$

Tổng có trọng số theo bin (equal-width từ AIO25M04LGBM02):

$$\text{Bin}_0 : G_0 = 2(-2) = -4, \ H_0 = 2; \quad \text{Bin}_1 : G_1 = 2(1) = 2, \ H_1 = 2; \quad \text{Bin}_2 : G_2 = 1(7) = 7, \ H_2 = 1.$$

Gộp theo rìa sau bin 0:

$$L = \text{Bin}_0 : (G_L, H_L) = (-4, 2), \quad R = \text{Bin}_1 \cup \text{Bin}_2 : (G_R, H_R) = (2 + 7, 2 + 1) = (9, 3).$$

$$\mathcal{G}_{\text{GOSS}} = \frac{(-4)^2}{2} + \frac{9^2}{3} = 8.00 + 27.00 = 35.00.$$

Với $35.00 \in [34.50, 35.50] \Rightarrow$, chọn phương án B.

AIO25M04LGBM06: Dùng **approximate quantile** cho binning với $B = 3$. Chọn rìa tại các khoảng hở gần $T_1 \approx 2$ và $T_2 \approx 4$, thu được ba bin:

$$\text{Bin}_0 = \{2, 4\}, \quad \text{Bin}_1 = \{6, 9\}, \quad \text{Bin}_2 = \{12, 15\}.$$

Xét các rìa: *sau bin 0, sau bin 1, sau bin 2*. Rìa nào *không* cho điểm số tách lớn nhất (không tối ưu) nhưng vẫn *hợp lệ* (không tạo nhánh rỗng)?

- A. Sau bin 0.
- B. Sau bin 1.
- C. Sau bin 2.
- D. Thiếu dữ kiện.

Đáp án đúng: A. Sau bin 0.

Giải thích:

Công thức sử dụng:

$$\mathcal{G} = \frac{G_L^2}{H_L} + \frac{G_R^2}{H_R}, \quad G_{\text{Bin}_0} = (-6) + (-4) = -10, \ H_{\text{Bin}_0} = 2;$$

$$G_{\text{Bin}_1} = (-2) + (+1) = -1, \ H_{\text{Bin}_1} = 2; \quad G_{\text{Bin}_2} = (+4) + (+7) = 11, \ H_{\text{Bin}_2} = 2.$$

Sau bin 0 (trái = Bin0, phải = Bin1 ∪ Bin2):

$$(G_L, H_L) = (-10, 2), \quad (G_R, H_R) = (-1 + 11, 2 + 2) = (10, 4),$$

$$\mathcal{G}_{(0)} = \frac{(-10)^2}{2} + \frac{10^2}{4} = 50 + 25 = 75.00.$$

Sau bin 1 (trái = Bin0 ∪ Bin1, phải = Bin2):

$$(G_L, H_L) = (-10 - 1, 2 + 2) = (-11, 4), \quad (G_R, H_R) = (11, 2),$$

$$\mathcal{G}_{(1)} = \frac{(-11)^2}{4} + \frac{11^2}{2} = 30.25 + 60.50 = 90.75.$$

Sau bin 2 (trái = Bin0 ∪ Bin1 ∪ Bin2, phải = ∅) là *không hợp lệ* vì nhánh phải rỗng.

Rìa tối ưu là *sau bin 1* (gain 90.75); rìa *sau bin 0* cho gain 75.00 (không tối ưu nhưng hợp lệ).

Do đó chọn **A**.

2 Thực hành

Mô tả bài toán cho cả 4 thuật toán RF, XGBoost, Ada Boost, Gradient Boost:

Trong bài toán này, chúng ta được cung cấp một tập dữ liệu về thông tin của nhân viên trong một công ty (tải tập dữ liệu **tại đây**). Nhiệm vụ đặt ra là xây dựng các chương trình để phân tích và xử lý tập dữ liệu này, từ đó trả lời các câu hỏi trắc nghiệm liên quan.

Thực hiện các yêu cầu sau đây

1. Đọc dữ liệu

Sử dụng thư viện `pandas` để đọc file `.csv` được cung cấp, sau đó hiển thị ra màn hình để hiểu các trường dữ liệu.

2. Label Encoding

Chuyển đổi các cột dữ liệu dạng chữ (cụ thể là cột “Gender” và “Position”) sang dạng số bằng cách sử dụng `LabelEncoder` từ thư viện `sklearn`.

3. Tách dữ liệu thành danh sách các feature (X) và nhãn (y)

- Sử dụng các cột “Gender”, “Experience (Years)” và “Position” làm đặc trưng đầu vào X.
- Sử dụng cột “Salary” làm nhãn y.

4. Tách tập dữ liệu thành tập huấn luyện và kiểm tra

- Chia dữ liệu thành tập huấn luyện (`X_train`, `y_train`) và tập kiểm tra (`X_test`, `y_test`) với tỷ lệ 80:20.
- Đảm bảo rằng việc chia tách dữ liệu là ngẫu nhiên nhưng tái lập được với `random_state=42`.

2.1 Random Forest

Nhập các thư viện cần thiết và tải dữ liệu.

```
1 # Cài đặt thư viện hỗ trợ Random Forest
2 import pandas as pd
3 import seaborn as sns
4 from sklearn.ensemble import RandomForestRegressor
5 from sklearn.model_selection import train_test_split
6 from sklearn.metrics import mean_squared_error, r2_score
7 from sklearn.preprocessing import LabelEncoder
8
9 # Tải và đọc dữ liệu
10 !wget https://raw.githubusercontent.com/
11 data = pd.read_csv("/content/my_xxxx.csv")
```

AIO25M04RF07: Khái niệm “bagging” trong Random Forest có ý nghĩa gì đối với sự đa dạng của các cây trong rừng?

- A. Tăng độ sâu của từng cây để tăng đa dạng.
- B. Sử dụng các tập dữ liệu huấn luyện khác nhau cho mỗi cây để tạo ra sự đa dạng.
- C. Thay đổi số lượng đặc trưng tại mỗi nút phân chia.
- D. Áp dụng các thuật toán tối ưu hóa khác nhau cho mỗi cây.

Đáp án đúng: B

Giải thích:

Bagging (Bootstrap Aggregating) tạo ra các tập dữ liệu bootstrap khác nhau bằng cách lấy mẫu có hoàn lại từ tập dữ liệu gốc. Điều này có nghĩa là một điểm dữ liệu có thể được chọn nhiều lần trong cùng một mẫu bootstrap, tạo ra sự đa dạng giữa các cây. Từ đó, mỗi cây sẽ học được những quy luật hơi khác nhau, tạo ra một khu rừng đa dạng. Do đó, ta chọn đáp án **B**.

AIO25M04RF08: Hãy sắp xếp lại các bước thực hiện thuật toán Random Forest theo thứ tự đúng để hoàn thiện quy trình.

1. Tính entropy hoặc Gini để chọn đặc trưng tốt nhất.
2. Lặp lại quá trình chọn đặc trưng tốt nhất và loại cột đã chọn cho đến khi không còn đặc trưng nào.
3. Loại bỏ đặc trưng đã được chọn ra khỏi bảng dữ liệu.
4. Tạo N bootstrapped dataset từ dữ liệu gốc.
5. Chọn ngẫu nhiên 2 đặc trưng từ dataset.
6. Xây dựng một cây quyết định cho mỗi bootstrapped dataset.

- A. $6 \rightarrow 5 \rightarrow 4 \rightarrow 1 \rightarrow 3 \rightarrow 2$.
- B. $4 \rightarrow 6 \rightarrow 5 \rightarrow 1 \rightarrow 3 \rightarrow 2$.
- C. $6 \rightarrow 4 \rightarrow 5 \rightarrow 1 \rightarrow 3 \rightarrow 2$.
- D. $5 \rightarrow 6 \rightarrow 1 \rightarrow 3 \rightarrow 4 \rightarrow 2$.

Đáp án đúng: B

Giải thích:

Các bước thực hiện thuật toán Random Forest theo thứ tự:

- (4) Tạo N bootstrap datasets từ dữ liệu gốc.
- (6) Với mỗi bootstrap dataset, xây dựng một cây quyết định.
- (5) Ở mỗi nút của cây: chọn ngẫu nhiên một tập con đặc trưng (feature randomness).
- (1) Dùng Gini/Entropy để chọn đặc trưng tốt nhất trong tập con đó.
- (3) Loại đặc trưng vừa chọn khỏi xét duyệt tại nút hiện tại.

(2) Lặp lại quá trình tách nút cho đến khi dừng (hết đặc trưng/đạt điều kiện dừng).

Dựa theo trình tự thực hiện trên, ta chọn đáp án **B**.

AIO25M04RF09: Random Forest có khả năng xử lý dữ liệu thiếu (missing data) như thế nào?

- A. Random Forest không thể xử lý dữ liệu thiếu.
- B. Sử dụng trung bình để điền dữ liệu thiếu.
- C. Tự động bỏ qua các mẫu có dữ liệu thiếu.
- D. Sử dụng các kỹ thuật nội suy trong quá trình huấn luyện cây.

Đáp án đúng: D

Giải thích:

Random Forest xử lý dữ liệu thiếu bằng cách:

- (1) Điền giá trị tạm (mean/median/mode) cho các ô thiếu.
- (2) Huấn luyện cây quyết định. Nếu tại một nút gặp giá trị thiếu, cây có thể dùng surrogate splits (đặc trưng thay thế có tương quan cao) để quyết định nhánh đi.
- (3) Sau khi có mô hình, sử dụng chính mô hình cây để dự đoán lại các giá trị bị thiếu dựa trên mối quan hệ với các đặc trưng khác.
- (4) Quá trình có thể lặp nhiều vòng để giá trị ước lượng ngày càng chính xác.

Từ đó, ta nhận thấy Random Forest không chỉ điền giá trị trung bình đơn giản hay bỏ qua dữ liệu thiếu, mà còn áp dụng các kỹ thuật nội suy có điều kiện trong quá trình huấn luyện cây bao gồm surrogate splits, dự đoán lại giá trị thiếu, và lặp nhiều vòng. Do đó, ta chọn đáp án đúng là **D**.

AIO25M04RF10: So với các phương pháp ensemble khác như Gradient Boosting, Random Forest thường có ưu điểm gì trong việc xử lý dữ liệu lớn và đa dạng?

- A. Random Forest khó bị overfitting hơn.
- B. Random Forest có thời gian huấn luyện nhanh hơn.
- C. Random Forest có thể song song hóa dễ dàng hơn do các cây độc lập.
- D. Random Forest đạt được độ chính xác cao hơn trong mọi trường hợp.

Đáp án đúng: C

Giải thích:

Vì mỗi cây được huấn luyện trên một bộ dữ liệu (bootstrap sample) riêng và được tạo ra một cách độc lập, nên quá trình xây dựng mỗi cây cũng hoàn toàn độc lập với nhau. Cây thứ nhất không cần chờ cây thứ hai học xong, và cũng không phụ thuộc vào kết quả của bất kỳ cây nào khác, dẫn tới việc Random Forest sở hữu tính song song hóa phù hợp với dữ liệu lớn và đa dạng. Do đó, ta chọn đáp án **C**.

AIO25M04RF11: Sử dụng thư viện `sklearn.metrics`, áp dụng các hàm `mean_squared_error` và `r2_score` để tính toán giá trị MSE và R^2 của mô hình Random Forest trên tập kiểm tra (sử dụng các tham số `n_estimators=50` và `random_state=42`). Giá trị MSE và R^2 là bao nhiêu (làm tròn tới 4 chữ số thập phân)?

- A. MSE: 981772731.6793, R^2 : 0.3121.
- B. MSE: 827087272.8357, R^2 : 0.6572.
- C. MSE: 827087272.8357, R^2 : 0.3121.
- D. MSE: 981772731.6793, R^2 : 0.6572.

Đáp án đúng: A

```

1  '''
2  Phần huấn luyện mô hình Random Forest
3  n_estimators: 50,
4  random_state: 42
5  '''
6  # Dự đoán kết quả từ tập test.
7  predictions = forest.predict(X_test)
8
9  # Tính MSE làm tròn tới 4 chữ số thập phân.
10 print("MSE:", round(mean_squared_error(y_test, predictions), 4))
11
12 # Tính R2 làm tròn tới 4 chữ số thập phân.
13 print("R2:", round(r2_score(y_test, predictions), 4))

```

```

predictions = forest.predict(X_test)
print("MSE:", round(mean_squared_error(y_test, predictions), 4))
print("R2:", round(r2_score(y_test, predictions), 4))

MSE: 981772731.6793
R2: 0.3121

```

AIO25M04RF12: Hãy thử nghiệm số lượng cây của mô hình Random Forest, với các giá trị `n_estimators` khác nhau (10, 20, 50, 100), số lượng cây nào đem lại MSE (Mean Squared Error) nhỏ nhất? (`random_state=42`)

- A. 10 cây.
- B. 20 cây.
- C. 50 cây.
- D. 100 cây.

Đáp án đúng: B

```

1 # Khởi tạo giá trị đầu cho Best MSE và Best Trees
2 best_mse = float('inf')
3 best_trees = None
4
5 # Tính MSE cho từng n_estimators khác nhau:
6 for count in [10, 20, 50, 100]:
7     model = RandomForestRegressor(n_estimators=count, random_state=42) # Khởi tạo mô h
8                                     ình Random Forest Regression với
9                                     random_state=42
10
11     model.fit(X_train, y_train)
12     pred = model.predict(X_test)
13     mse = mean_squared_error(y_test, pred)
14     r2 = r2_score(y_test, pred)
15
16     print(f'{count} trees: R2: {r2:.4f}, MSE: {mse:.4f}')
17
18 # Cập nhật best MSE và best_trees
19 if mse < best_mse:
20     best_mse = mse
21     best_trees = count
22
23 print(f'Optimal tree count: {best_trees} with MSE {best_mse:.4f}')

```

```

10 trees → R2: 0.2145, MSE: 1120987367.6711
20 trees → R2: 0.3187, MSE: 972381168.1178
50 trees → R2: 0.3121, MSE: 981772731.6793
100 trees → R2: 0.2933, MSE: 1008555152.7152
Optimal tree count: 20 with MSE 972381168.1178

```

AIO25M04RF13: Hãy thử nghiệm các giá trị độ sâu của cây `max_depth` từ 1 đến 10, độ sâu nào mang lại MSE (Mean Squared Error) nhỏ nhất? (`random_state=42, n_estimators=100`)

- A. Độ sâu 1.
- B. Độ sâu 2.
- C. Độ sâu 6.
- D. Độ sâu 8.

Đáp án đúng: B

```

1 # Khởi tạo giá trị đầu cho Best MSE và Best Depth
2 best_mse = float('inf')
3 best_depth = None
4
5 # Tính MSE cho từng max_depth khác nhau:

```

```

6 for depth in range(1, 11):
7     model = RandomForestRegressor(
8         n_estimators=100, max_depth=depth, random_state=42 # Khởi tạo mô hình Random
9         )                                                    Forest Regression với random_state=42
10    model.fit(X_train, y_train)
11    pred = model.predict(X_test)
12    mse = mean_squared_error(y_test, pred)
13    r2 = r2_score(y_test, pred)
14    print(f'Depth {depth}: R2:{r2:.4f}, MSE:{mse:.4f}')
15
16    # Cập nhật best MSE và best_depth
17    if mse < best_mse:
18        best_mse = mse
19        best_depth = depth
20
21 print(f'Optimal depth: {best_depth} with MSE {best_mse:.4f}')

```

```

Depth 1 → R2: 0.2393, MSE: 1085651058.3962
Depth 2 → R2: 0.4411, MSE: 797650228.2268
Depth 3 → R2: 0.4170, MSE: 832066419.1666
Depth 4 → R2: 0.4258, MSE: 819471601.4714
Depth 5 → R2: 0.4245, MSE: 821295930.6274
Depth 6 → R2: 0.3979, MSE: 859304956.5134
Depth 7 → R2: 0.3820, MSE: 882038673.3405
Depth 8 → R2: 0.3428, MSE: 937992196.6749
Depth 9 → R2: 0.3141, MSE: 978872583.9293
Depth 10 → R2: 0.2998, MSE: 999299459.8934
Optimal depth: 2 with MSE 797650228.2268

```

2.2 Ada/Gra Boost

Nhập các thư viện cần thiết và tải dữ liệu.

```

1 # Cài đặt thư viện hỗ trợ AdaBoost và GradientBoost
2 from sklearn.metrics import mean_squared_error, r2_score
3 import pandas as pd
4 from sklearn.model_selection import train_test_split
5 from sklearn.preprocessing import LabelEncoder
6 from sklearn.ensemble import AdaBoostRegressor, GradientBoostingRegressor
7 from sklearn.metrics import mean_squared_error
8 import numpy as np
9
10 # Tải và đọc dữ liệu

```

```
11 !gdown 1x8SWX93sFcsKSvDjfknuM3HieMq5ZU05
12 data = pd.read_csv("/content/my_xxxx.csv")
```

AIO25M04ABGB01: Điểm khác biệt chính giữa AdaBoost và Gradient Boosting trong cách mà chúng cải thiện mô hình là gì?

- A. AdaBoost tập trung vào việc sửa lỗi của các mẫu dữ liệu có lỗi cao nhất, còn Gradient Boosting tập trung vào giảm thiểu giá trị lỗi toàn bộ bằng cách sử dụng đạo hàm.
- B. AdaBoost sử dụng các mô hình con yếu, trong khi Gradient Boosting chỉ sử dụng mô hình con mạnh.
- C. AdaBoost không thể dẫn đến overfitting, trong khi Gradient Boosting dễ bị overfitting.
- D. AdaBoost và Gradient Boosting có cùng cách tiếp cận trong việc cải thiện mô hình qua các bước lặp.

Đáp án đúng: A

Giải thích:

Ôn lại về cách hoạt động của hai thuật toán Ada Boost và Gradient Boost:

- Ada Boost tập trung vào việc xác định các mẫu dữ liệu bị dự đoán sai và đánh trọng số cao hơn cho các mẫu đó trong khi các mẫu đúng sẽ được đánh trọng số thấp hơn. Như vậy, thuật toán sẽ ép mô hình phải tập trung vào các mẫu dữ liệu khó hơn để có thể cải thiện độ chính xác.
- Gradient Boosting tối ưu mô hình bằng cách giảm thiểu một hàm mất mát (loss function). Để làm vậy, thuật toán tính toán sự khác biệt giữa dự đoán hiện tại và giá trị thực tế. Mỗi mô hình con mới được thêm vào sẽ được huấn luyện để dự đoán chính phần lỗi dư này, từ đó giúp mô hình tổng thể tiến dần đến kết quả chính xác hơn.

Từ cơ chế hoạt động của 2 thuật toán, ta suy luận rằng đáp án **A** là đáp án đúng.

AIO25M04ABGB02: Điều gì xảy ra khi bạn tăng số lượng mô hình con (estimators) trong AdaBoost hoặc Gradient Boosting? (Thực hiện thay đổi tham số estimators để kiểm tra)

- A. Hiệu suất mô hình luôn tăng khi tăng số lượng mô hình con.
- B. Hiệu suất có thể tăng, nhưng nếu quá cao sẽ gây overfitting.
- C. Hiệu suất giảm dần khi tăng số lượng mô hình con.
- D. Hiệu suất không bị ảnh hưởng bởi số lượng mô hình con.



Đáp án đúng: B

Có thể kiểm chứng bằng cách sử dụng một trong 2 thuật toán Ada Boost và Gradient Boost như sau:

```

1 test_errors = []
2
3 # Danh sách các mô hình con n_estimators
4 n_estimators_list = [10,20,50,100,200,500]
5
6 # Khởi tạo mô hình Gradient hoặc Adaboost
7 for n in n_estimators_list:
8     model = GradientBoostingRegressor(n_estimators=n, learning_rate=0.1, random_state=
9                                         42)
10    # model = AdaBoostRegressor(n_estimators=n, learning_rate=0.1, random_state=42)
11    model.fit(X_train, y_train)
12
13    # Thiết lập MSE để đánh giá trực quan hóa
14    test_errors.append(mean_squared_error(y_test, model.predict(X_test)))
15
16 # Trực quan hóa kết quả
17 plt.plot(n_estimators_list, test_errors, label="Test MSE")
18 plt.xlabel("n_estimators")
19 plt.ylabel("MSE")
20 plt.legend()
21 plt.title("Ảnh hưởng của số lượng mô hình con trên thuật toán Gradient Boost")
22 # plt.title("Ảnh hưởng của số lượng mô hình con trên thuật toán Ada Boost")
23 plt.show()

```



AIO25M04ABGB03: Khi nào overfitting có thể xảy ra trong AdaBoost và Gradient Boosting?
(Hãy thử nghiệm với code các trường hợp trên và đưa ra kết luận)

- A. Khi sử dụng quá ít mô hình con.
- B. Khi sử dụng giá trị learning rate quá cao và số lượng mô hình con quá nhiều.
- C. Overfitting không xảy ra trong Gradient Boosting.

D. Khi mô hình không có đủ dữ liệu để huấn luyện.

Đáp án đúng: B


Có thể kiểm chứng bằng cách sử dụng một trong 2 thuật toán Ada Boost và Gradient Boost như sau:

```


1 learning_rates = [0.01, 0.1, 0.5]
2 plt.figure(figsize=(10,6))
3
4 for lr in learning_rates:
5     test_errors = []
6     # Danh sách các mô hình con n_estimators
7     n_estimators_list = [10,20,50,100,200,500]
8
9     # Khởi tạo mô hình Gradient hoặc Adaboost
10    for n in n_estimators_list:
11        # model = GradientBoostingRegressor(n_estimators=n, learning_rate=lr,
12                                           random_state=42)
13        model = AdaBoostRegressor(n_estimators=n, learning_rate=lr, random_state=42)
14        model.fit(X_train, y_train)
15
16        # Thiết lập MSE để đánh giá trực quan hóa
17        test_errors.append(mean_squared_error(y_test, model.predict(X_test)))
18    print(f"lr={lr}:", test_errors)
19    plt.plot(n_estimators_list, test_errors, label=f"lr={lr}")
20
21 plt.xlabel("n_estimators")
22 plt.ylabel("Test MSE")
23 plt.legend()
24 # plt.title("Kiểm chứng overfitting qua ảnh hưởng của Learning Rate và Mô hình con trên
25 #           thuật toán Gradient Boost")
26 plt.title("Kiểm chứng overfitting qua ảnh hưởng của Learning Rate và Mô hình con trên
27           thuật toán Ada Boost")
28 plt.show()

```

Kiểm chứng overfitting qua ảnh hưởng của Learning Rate và Mô hình con trên thuật toán Gradient Boost



Kiểm chứng overfitting qua ảnh hưởng của Learning Rate và Mô hình con trên thuật toán Ada Boost



AIO25M04ABGB04: Gradient Boosting cho phép đánh giá tầm quan trọng của các đặc trưng. Tầm quan trọng của đặc trưng nào sẽ có khả năng cao nhất trong bài toán dự đoán lương nhân viên? (Dùng phương thức `feature_importances_` có sẵn trong model)(`random_state=42`, `n_estimators=50`)

- A. Gender.
- B. Experience (Years).
- C. Position.
- D. ID.

Đáp án đúng: B

```

1 importances_grad = grad_regressor.feature_importances_
2 feature_names = X.columns
3 feature_importance_df = pd.DataFrame({
4                                     'Feature': feature_names,
5                                     'Importance': importances_grad
6                                 })
7 feature_importance_df = feature_importance_df.sort_values(
8                                     by='Importance',
9                                     ascending=False
10                                )
11 print(feature_importance_df)

```

	Feature	Importance
1	Experience (Years)	0.580842
2	Position	0.410666
0	Gender	0.008493

AIO25M04ABGB05: Sử dụng thư viện `sklearn.metrics`, áp dụng hàm `mean_squared_error` và `r2_score` để tính toán giá trị MSE và R^2 (sử dụng tham số của 2 mô hình là `n_estimators=50`, `random_state=42`) trên tập Test, trả lời câu hỏi: Dựa trên 2 giá trị trên, hiệu suất của 2 mô hình Ada & Gradient Boost như thế nào?

- A. Với giá trị R^2 từ 0.7-0.8, mô hình đang hoạt động khá tốt, giá trị MSE khá tương đối không cao không thấp.
- B. Với giá trị R^2 từ 0.6-0.7, mô hình đang hoạt động ở mức khá, bao quát được một phần nhưng cũng nhiều sai sót, giá trị MSE khá cao.
- C. Với giá trị R^2 từ 0.4-0.5, mô hình đang hoạt động ở mức tệ, không nắm bắt được phương sai trong dữ liệu. Giá trị MSE lớn.

- D. Với giá trị R^2 từ 0.1-0.2, mô hình dường như không học được từ dữ liệu. Giá trị MSE siêu lớn thể hiện sự sai sót khi mô hình không thể học.

Đáp án đúng: C

```
1 # Tính MSE và R2 cho Ada Boost
2 y_pred_ada = ada_regressor.predict(X_test)
3 print("AdaBoost Regressor Performance:")
4 print(f"Mean Squared Error: {mean_squared_error(y_test, y_pred_ada)}")
5 print(f"R^2 Score: {r2_score(y_test, y_pred_ada)}")
6
7 # Tính MSE và R2 cho Gradient Boost
8 y_pred_gb = grad_regressor.predict(X_test)
9 print("Gradient Boosting Regressor Performance:")
10 print(f"Mean Squared Error: {mean_squared_error(y_test, y_pred_gb)}")
11 print(f"R^2 Score: {r2_score(y_test, y_pred_gb)}")
12
```

```
AdaBoost Regressor Performance:
Mean Squared Error: 822155975.0926577
R^2 Score: 0.4239172660697248
```

```
Gradient Boosting Regressor Performance:
Mean Squared Error: 797328906.1114432
R^2 Score: 0.4413135341836453
```

2.3 XGBoost

Cài đặt và nhập các thư viện cần thiết

```
1 # Cài đặt thư viện XGBoost
2 !pip install xgboost
3
4 # Nhập các thư viện cần thiết
5 import pandas as pd
6 import matplotlib.pyplot as plt
7 import seaborn as sns
8
9 import xgboost as xgb
10 from xgboost import XGBRegressor
11
12 from sklearn.model_selection import train_test_split
13 from sklearn.preprocessing import LabelEncoder
```

```
14 from sklearn.metrics import mean_squared_error, r2_score
15
16 # Tải và đọc dữ liệu
17 !gdown 1x8SWX93sFcsKSvDjfknuM3HieMq5ZU05
18 data = pd.read_csv("/content/my_xxxx.csv")
```

AIO25M04XGB07: Dựa vào đoạn mã được cung cấp để trả lời câu hỏi, XGBoost được khởi tạo đúng với mô tả nào sau đây?

```
1 params = {
2     "n_estimators": 50,
3     "random_state": 42
4 }
5 xgb_model = XGBRegressor(**params)
```

- A. Mô hình dùng cho bài toán phân loại, có 50 cây và đặt *random_state* để điều chỉnh số lượng cây trong mô hình.
- B. Mô hình dùng cho bài toán phân loại, có 42 cây và *random_state* để giúp đảm bảo kết quả có thể tái hiện lại.
- C. Mô hình dùng cho bài toán hồi quy, có 50 cây và *random_state* để điều chỉnh số lượng cây trong mô hình.
- D. Mô hình dùng cho bài toán hồi quy, có 50 cây và *random_state* để giúp đảm bảo kết quả có thể tái hiện lại.

Đáp án đúng: D

AIO25M04XGB08: Sau khi huấn luyện mô hình ở câu trên, đặc trưng nào được sử dụng nhiều nhất để phân nhánh? Hãy tìm hiểu và sử dụng hàm `.get_score()` với tham số `importance_type="weight"`. (Tài liệu tham khảo)

- A. Gender.
- B. Experience.
- C. Position.
- D. Salary.

Đáp án đúng: B

```
1 xgbooster = xgb_model.get_booster()
2 importances_xgb = xgbooster.get_score(importance_type='weight')
3
4 # Convert từ dict sang dataframe
```

```

5 df = pd.DataFrame(list(importances_xgb.items()), columns=['Feature', 'Importance'])
6 print(df)
7

```

	Feature	Importance
0	Gender	289.0
1	Experience (Years)	1017.0
2	Position	828.0

AIO25M04XGB09: Tiếp tục sử dụng mô hình ở câu **AIO2M04XGB07**, hãy in ra cây đầu tiên (0). Điều kiện để phân nhánh lần thứ 2 (Root Node tính là 1 lần) được hiển thị trên hình là? Hãy tìm hiểu và sử dụng hàm `.plot_tree()` với tham số bắt buộc phải có là `num_trees=0`.


- A. Position < 5.
- B. Position > 5.
- C. Experience < 8.
- D. Experience > 8.

Đáp án đúng: A

```

1 # Vẽ cây đầu tiên (num_trees=0)
2 fig, ax = plt.subplots(figsize=(40, 20))
3 plot_tree(xgb_model, num_trees=0, rankdir="LR", ax=ax) # bắt buộc phải có num_trees=0
4 ax.set_title("XGBoost - Tree 0", fontsize=16)
5 fig.tight_layout()
6 plt.show()
7

```



AIO25M04XGB10: Tiếp tục sử dụng mô hình ở câu **AIO25M04XBG07**, hãy in ra cây đầu tiên (0). Nếu một input có Experience (Year) = 4 và Position = 4, cây thứ 0 này sẽ trả về kết quả là? Hãy tìm hiểu và sử dụng hàm `.plot_tree()` với tham số bắt buộc phải có là `num_trees=0`.


- A. -3589.26025.
- B. -3555.0376.
- C. 5899.46289.
- D. -7516.56006.

Đáp án đúng: B

```

1 # Vẽ cây đầu tiên (num_trees=0)
2 fig, ax = plt.subplots(figsize=(40, 20))
3 plot_tree(xgb_model, num_trees=0, rankdir="LR", ax=ax) # bắt buộc phải có num_trees=0
4 ax.set_title("XGBoost - Tree 0", fontsize=16)
5 fig.tight_layout()
6 plt.show()
7

```



AIO25M04XGB11: Giá trị đánh giá MSE và R^2 trên tập Test cho mô hình XGBoost trên xấp xỉ là? Hãy sử dụng hàm `mean_squared_error()` và `r2_score()`. (`random_state=42, n_estimators=50`)

- A. MSE = 1182725453, R^2 Score = 0.3918.
 B. MSE = 1325373291, R^2 Score = 0.2904.
 C. MSE = 1153401856, R^2 Score = 0.1918.
 D. MSE = 1153401856, R^2 Score = 0.2904.

Đáp án đúng: C

```
1 # Dự đoán kết quả bằng thuật toán XG Boost trên tập Test.
2 y_pred_xgb = xgb_model.predict(X_test)
3
4 print("XGBoost Regressor Performance:")
5 print(f"Mean Squared Error: {mean_squared_error(y_test, y_pred_xgb)}")
6 print(f"R^2 Score: {r2_score(y_test, y_pred_xgb)}")
```

XGBoost Regressor Performance:
Mean Squared Error: 1153401856.0
R² Score: 0.19181406497955322

2.4 Tổng quát

AIO25M04ABGBXGB01: (Cho cả 3 phần) Hãy xem đây như là một bài toán thực nghiệm, thay thế từ mô hình Random Forest, XGBoost, AdaBoost, Gradient Boost vào dữ liệu trên. Sau đó đánh giá bộ dữ liệu trên tập test và đưa ra mô hình tốt nhất được chọn tối ưu cho bộ dữ liệu này. (Thực hiện với các siêu tham số chung: `n_estimators = 50`, `random_state=42`)

- A. Random Forest.
- B. XGBoost.
- C. AdaBoost.
- D. Gradient Boost.

Đáp án đúng: D

```
1 import pandas as pd
2 import numpy as np
3 from sklearn.model_selection import train_test_split
4 from sklearn.preprocessing import LabelEncoder
5 from sklearn.ensemble import AdaBoostRegressor, GradientBoostingRegressor,
6                                     RandomForestRegressor
7 from xgboost import XGBRegressor
8 from sklearn.metrics import mean_squared_error, r2_score
9
10 # Initialize models
11 models = {
12     'Random Forest': RandomForestRegressor(n_estimators=50, random_state=42),
13     'XGBoost': XGBRegressor(n_estimators=50, random_state=42),
14     'AdaBoost': AdaBoostRegressor(n_estimators=50, random_state=42),
15     'Gradient Boosting': GradientBoostingRegressor(n_estimators=50, random_state=42)
16 }
17
18 # Evaluate models
19 results = {}
20
21 for name, model in models.items():
22     # Train the model
23     model.fit(X_train, y_train)
24
25     # Predict on the test set
26     y_pred = model.predict(X_test)
27
28     # Calculate R^2 and MSE
29     r2 = r2_score(y_test, y_pred)
30     mse = mean_squared_error(y_test, y_pred)
31
32     results[name] = {'R^2': r2, 'MSE': mse}
33
34 # Display results
35 results_df = pd.DataFrame(results).T
36 print(results_df)
```

36

	R ²	MSE
Random Forest	0.312074	9.817727e+08
XGBoost	0.191814	1.153402e+09
AdaBoost	0.423917	8.221560e+08
Gradient Boosting	0.441314	7.973289e+08